

地理加權迴歸GWR:
基本理論、Package操作、手刻實作

YUNG-CHUN LAN

1. GWR 理論背景

2. GWR 估計流程

3. Georgia 縣級資料實作

- R Package 復刻分析流程
- 手刻 GWR 核心內容
- 套件 vs 手刻結果比較
- 結果視覺化

空間資料具地區差異性，不同變數間的關係可能隨地區改變

範例：屋齡與房價

“鄉村地區老房子有特色，可能越老越貴；

都市地區老房子品質差，可能越老越便宜”

傳統全域迴歸模型

共享同一組參數，較難呈現空間局部差異

GWR

引入距離加權觀念，在不同位置估計局部迴歸係數，使模型能夠描述變數關係的空間差異。

空間資料特性

不同地區可能具不同社會、經濟、地理條件
相同解釋變數在不同位置可能呈現不同關係

定義:空間非平穩 Spatial Non-Stationary

變數之間的關係會隨空間位置改變

造成空間非平穩可能原因:

1. 抽樣誤差
2. 變數關係確實存在地區差異


GWR 理論背景 – 傳統全域迴歸模型的限制

全域迴歸模型

$$\text{housing prices} = \beta_0 + \beta_1 \text{ building age} + \beta_2 \text{ area} + \beta_3 \text{ unemployment} + \dots$$

問題

使用同一組係數估計整個國家，得到的模型只是整個國家的平均關係，不一定適用所有地區



全域模型殘差圖：估計倫敦房價

Source: Fotheringham et al. (2012). Geographically Weighted Regression. p.37

1. 共 n 個觀測點，每個點都建構一組迴歸模型，共建構 n 組迴歸模型
2. 使用其他觀測點的資料訓練模型
3. 距迴歸點越近的觀測點，權重越大；距迴歸點越遠的觀測點，權重越小
4. 迴歸點不一定要在觀測點上

GWR 模型: 每個點都是一組迴歸模型，共 n 組迴歸模型

$$\mathbf{y} = (\mathbf{B} \otimes \mathbf{X}) \mathbf{1} + \varepsilon$$

where

$$\mathbf{B} = \begin{bmatrix} \beta_0(u_1, v_1) & \beta_1(u_1, v_1) & \cdots & \beta_k(u_1, v_1) \\ \beta_0(u_2, v_2) & \beta_1(u_2, v_2) & \cdots & \beta_k(u_2, v_2) \\ \vdots & \vdots & \ddots & \vdots \\ \beta_0(u_n, v_n) & \beta_1(u_n, v_n) & \cdots & \beta_k(u_n, v_n) \end{bmatrix}, \quad \mathbf{1} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

GWR 模型 – 係數解

一般迴歸模型係數解 (最小平方法):

$$\hat{\beta} = (X^T X)^{-1} X^T \mathbf{y}$$

GWR 模型係數解 (局部加權最小平方法):

$$\hat{\beta}(u_i, v_i) = (X^T W(u_i, v_i) X)^{-1} X^T W(u_i, v_i) \mathbf{y}$$

where

$$W(u_i, v_i) = \begin{bmatrix} w_{i1} & 0 & \cdots & 0 \\ 0 & w_{i2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & w_{in} \end{bmatrix}, w_{ik} : \text{the weight of } k\text{th data at location } i$$

GWR 模型 – 權重函數選擇

全域迴歸: 不管資料點 j 離迴歸點 i 多遠, 權重都是 1

$$w_{ij} = 1 \quad \forall i, j$$

最簡單局部方法: 距離內算, 距離外不算

$$w_{ij} = \begin{cases} 1, & d_{ij} < d \\ 0, & o.w. \end{cases}$$

問題: 不連續且視窗內權重都是1, 本質上只是範圍較小的全域迴歸

GWR 模型 – 權重函數選擇

較好的方法: 讓權重隨距離平滑下降(高斯權重)

$$w_{ij} = \exp\left[-\frac{d_{ij}^2}{2b^2}\right]$$

問題: 即使很遠的資料點, 也會被乘上權重

bi-square 權重: 平滑下降, 但超過範圍直接歸 0

$$w_{ij} = \begin{cases} [1 - (\frac{d_{ij}}{b})^2]^2, & d_{ij} < b \\ 0, & o.w. \end{cases}$$

1. 不像應切的移動視窗, 內部權重都是 1
2. 明確排除太遠的資料點
3. GWR 常用權重函數

GWR 觀念: 帶寬 Bandwidth

定義: 帶寬 bandwidth

GWR 權重函數中的尺度參數，控制距離對空間權重的影響範圍。

帶寬越小，局部迴歸主要受鄰近觀測點影響，模型較能反映局部差異；

帶寬越大，較多觀測點參與估計，係數曲面較平滑，模型結果越接近全域迴歸。

- **固定帶寬 (fixed bandwidth):**

每個迴歸點採用相同範圍 b (空間資料密度不均時易導致估計偏誤)

- **可變帶寬 (adaptive bandwidth)**

資料點多的地方採用小範圍，資料點少的地方採用大範圍，保證每個迴歸點模型都使用合理資料量訓練

GWR 模型 – 可變帶寬形式

可變帶寬 1：用距離排序決定權重

$w_{ij} = \exp(\frac{-R_{ij}}{b})$, where R_{ij} : the rank of data point j at regression point i .

可變帶寬 2：讓每個點權重總和相同

$$\sum_j w_{ij} = C \forall i$$

GWR 模型 – 可變帶寬形式

可變帶寬 3 : 固定使用最近的 N 個鄰居 (最常見)

$$w_{ij} = \begin{cases} 1, & j \text{ is one of the } N \text{ points closest to the regression point } i. \\ 0, & o.w. \end{cases}$$

combine with bi-square:

$$w_{ij} = \begin{cases} [1 - (\frac{d_{ij}}{b})^2]^2, & j \text{ is one of the } N \text{ points closest to the regression point } i. \\ 0, & o.w. \end{cases}$$

GWR 模型 – 帶寬選擇

交叉驗證 CV: 預測 i 點時，不拿 i 點訓練

$$CV = \sum_{i=1}^n [y_i - \hat{y}_{\neq i}(b)]^2$$

廣義交叉驗證 GCV: 預測 i 點時，不拿掉 i 點，而是用複雜度懲罰模型

$$GCV = n \sum_{i=1}^n [y_i - \hat{y}_i(b)]^2 / (n - v_1)^2, \text{ where } v_1 = \text{tr}(\text{hat matrix } S)$$

AICc: 同時考慮模型配適度與複雜度，也可用在 Poisson GWR、Logistic GWR

$$AIC_c = 2n \log(\hat{\sigma}) + n \log(2\pi) + n \left[\frac{n + \text{tr}(S)}{n - 2 - \text{tr}(S)} \right]$$

BIC: 比 AICc 對模型複雜度施加更多懲罰，更傾向選擇簡單 (大帶寬) 模型

$$BIC = -2 \log(L) + k \log(n), \text{ where } L: \text{ model likelihood}$$

參考 Fotheringham et al. (2012). Geographically Weighted Regression. pp.97-102 估計流程:

1. 使用資料: 喬治亞州縣級資料
2. 使用 N 近鄰 bandwidth 搭配 bi-square 權重
3. 測試多個 bandwidth，選擇 AICc 表現最好的模型
4. 於地圖範圍設置 40*40 網格作為迴歸點
5. 於迴歸點訓練模型
6. 將各解釋變數之局部迴歸係數視覺化

GWR 實作: 資料介紹

使用 GWmodel 套件內建之 Georgia census data set

- 美國喬治亞州縣級人口普查資料
- 每筆觀測值代表喬治亞州的一個縣
- 159 筆觀測值、13 個變數

模型設定:

$$\begin{aligned} PctBach_i &= \beta_0(i) \\ &+ \beta_1(i)PctRural_i \\ &+ \beta_2(i)PctEld_i \\ &+ \beta_3(i)PctFB_i \\ &+ \beta_4(i)PctPov_i \\ &+ \beta_5(i)PctBlack_i \\ &+ \epsilon_i \end{aligned}$$

where i: ith point in the space.

變數名稱	角色	變數說明
AreaKey	識別變數	各 county 的識別編號
Latitude	座標變數	County centroid 的緯度
Longitud	座標變數	County centroid 的經度
TotPop90	背景變數	1990 年 county 總人口數
PctRural	解釋變數	County 中被定義為 rural population 的人口比例
PctBach	應變數	County 中具學士學位的人口比例
PctEld	解釋變數	County 中 65 歲以上人口比例
PctFB	解釋變數	County 中非美國出生人口比例
PctPov	解釋變數	County 中低於貧窮線人口比例
PctBlack	解釋變數	County 黑人人口比例
ID	識別變數	數值型 ID
X	空間座標	County centroid 的 X 座標
Y	空間座標	County centroid 的 Y 座標

Source: package 'GWmodel' documentation pp.16-17

GWR 實作: 使用 R Package “GWmodel”

bw.gwr() 參數內容

參數	意義	報告設定
formula	迴歸模型公式，指定 y 和 x 變數	PctBach ~ PctRural + PctEld + PctFB + PctPov + PctBlack
data	空間資料，須為Spatial*DataFrame 或 sf 物件	將套件原廠資料轉換為 SPDF
approach	bandwidth 選擇方法，可用 CV 或 AICc	approach = "AICc"
kernel	空間權重函數，決定距離如何轉成權重	kernel = "bisquare"
adaptive	是否使用 adaptive bandwidth	adaptive = TRUE
p	Minkowski distance 次方數，p = 2 是歐式距離	預設 p = 2
theta	是否旋轉座標系統，用於調整距離方向	預設 theta = 0
longlat	是否使用經緯度大圓距離	預設 FALSE
dMat	事先算好的距離矩陣	省略 (p=2 已自動計算距離)
parallel.method	是否使用平行運算	預設 FALSE
parallel.arg	平行運算的細部設定	預設 Null

輸出: 參數設定下最佳 bandwidth

Source: package ‘GWmodel’ documentation p.10

GWR 實作: 使用 R Package “GWmodel”

gwr.basic() 參數內容

參數	意義	報告設定
formula	迴歸模型公式	PctBach ~ PctRural + PctEld + PctFB + PctPov + PctBlack
data	空間資料，須為 Spatial*DataFrame 或 sf 物件	educ.spdf
regression.points	指定在哪些位置估計 local coefficients	40*40網格點
bw	bandwidth	bw.gwr()選定之最佳bandwidth
kernel	空間權重函數	"bisquare"
adaptive	是否使用 adaptive bandwidth	TRUE
p	Minkowski distance 的次方，p = 2 是歐式距離	預設 2
theta	是否旋轉座標系統	預設 0
longlat	是否使用經緯度大圓距離	預設 FALSE
dMat	事先算好的距離矩陣	省略
F123.test	是否進行 Leung 三個 F-tests	預設 FALSE
cv	是否計算 cross-validation 結果並放入輸出	預設 FALSE
W.vect	額外給定觀測值權重	預設 NULL
x	print() method 用，gwr.basic() 回傳的物件	不需自己設定
parallel.method	是否用平行運算	預設 FALSE
parallel.arg	平行運算的細部設定	預設 NULL


GWR 實作: 使用 R Package “GWmodel”

`gwr.basic()` 回傳內容

回傳項目	意義	報告設定
GW.arguments	儲存 GWR 模型參數設定	V
GW.diagnostic	模型診斷結果，如 RSS、AICc、 R^2	V
lm	對應的 global linear regression 結果	V
SDF	最重要的輸出，包含每個地點的 local coefficients、yhat、residual、standard errors、t-values 等	V
timings	模型開始與結束時間	X
this.call	當初執行的 function call	X
Ftest.res	若 <code>F123.test = TRUE</code> ，這裡會存 Leung's F-tests 結果	X

Source: package ‘GWmodel’ documentation p.40

GWR 實作: 使用 R Package “GWmodel”



GWR 實作: 手刻程式碼

基本估計函數設計:

函數	參數	輸出
grid()	x, nrow, y, ncol	nrow * ncol 網格點
cal_distance_matrix()	grid, obs	所有迴歸點至所有觀測點之距離矩陣
bisquare_adaptive_weight()	d, bw	各觀測點之於單一迴歸點之權重向量
local_lwr()	X, y, w	單一迴歸點之係數解
gwr_grid()	X, y, obs, grid, bw	所有迴歸點之係數解



迴圈次數 = 迴歸點個數

初始全域變數

選擇最佳 bandwidth (最小AICc):

函數	參數	輸出
calc_gwr_aicc	X, y, obs, bw	bandwidth=bw 下之 AICc
select_bw_aicc	X, y, obs, bw_canditates	1. 所有候選 bandwidths 之 AICc 2. 最佳bandwidth (最小AICc)



loop

套件與手刻結果比較

項目	GWmodel	手刻
Bandwidth 選擇	136	136
最小 AICc	850.8465	850.8465
係數估計差距最大值	3.531e-12	

GWR 實作: 視覺化

- 係數估計位置: 40 * 40 迴歸點
- 顏色意義: 各迴歸點估計值
- 州界外處理: NA 遮罩
- 結果: 各個變數均有一定程度之空間差異

(e.g.) PctBlack 在西南部係數較高，代表其在該區域正向關係較強。

