

Week 2 進度

- PPT 數學式修正
- 迴歸點修正為 159 個觀測點
- 完成套件+手刻 CV 程式碼
- CV 與 GCV 比較 (為何發展GCV方法)
- AIC、AICc 公式推導
- 尋找 AI 視覺化時使用的套件 (R basic image())
- 實作 Monte Carlo Permutation Test
- Leung F3 test: Leung 2000原論文、GWmodel套件、原文書參數比較

Week 3 進度

- 參考 Wheeler & Calder (2007). J Geogr Syst, 9(2), 145-166. 中模擬實驗內容，建構網格並設置真實係數，實作 GWR 模擬 (模擬流程、程式碼設計、結果比較)
- 補上 Monte Carlo Permutation Test流程
- 補上信賴區間推導

Week 4 預計進度

- 學習黃金切割搜尋演算法、完成程式碼實作

(底部橘色表示 week 1 後有更新的簡報頁面)

地理加權迴歸GWR:
基本理論、Package操作、手刻實作

YUNG-CHUN LAN

1. GWR 理論背景

2. GWR 估計流程

3. Georgia 縣級資料實作

- R Package 復刻分析流程
- 手刻 GWR 核心內容
- 套件 vs 手刻結果比較
- 結果視覺化

空間資料具地區差異性，不同變數間的關係可能隨地區改變

範例：屋齡與房價

“鄉村地區老房子有特色，可能越老越貴；

都市地區老房子品質差，可能越老越便宜”

傳統全域迴歸模型

共享同一組參數，較難呈現空間局部差異

GWR

引入距離加權觀念，在不同位置估計局部迴歸係數，使模型能夠描述變數關係的空間差異。

空間資料特性

不同地區可能具不同社會、經濟、地理條件
相同解釋變數在不同位置可能呈現不同關係

定義:空間非平穩 Spatial Non-Stationary

變數之間的關係會隨空間位置改變

造成空間非平穩可能原因:

1. 抽樣誤差
2. 變數關係確實存在地區差異


GWR 理論背景 – 傳統全域迴歸模型的限制

全域迴歸模型

$$\text{housing prices} = \beta_0 + \beta_1 \text{ building age} + \beta_2 \text{ area} + \beta_3 \text{ unemployment} + \dots$$

問題

使用同一組係數估計整個國家，得到的模型只是整個國家的平均關係，不一定適用所有地區



全域模型殘差圖：估計倫敦房價

Source: Fotheringham et al. (2012). Geographically Weighted Regression. p.37

1. 共 n 個觀測點，每個點都建構一組迴歸模型，共建構 n 組迴歸模型
2. 除了迴歸點本身，也使用其他觀測點的資料訓練模型
3. 距迴歸點越近的觀測點，權重越大；距迴歸點越遠的觀測點，權重越小
4. 迴歸點不一定要在觀測點上

GWR 模型形式

GWR 模型：每個點都是一組迴歸模型，共 n 組迴歸模型

$$\mathbf{y} = (\boldsymbol{\beta} \odot \mathbf{X}) \mathbf{1} + \boldsymbol{\varepsilon}$$

where

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0(u_1, v_1) & \beta_1(u_1, v_1) & \cdots & \beta_k(u_1, v_1) \\ \beta_0(u_2, v_2) & \beta_1(u_2, v_2) & \cdots & \beta_k(u_2, v_2) \\ \vdots & \vdots & \ddots & \vdots \\ \beta_0(u_n, v_n) & \beta_1(u_n, v_n) & \cdots & \beta_k(u_n, v_n) \end{bmatrix}_{n \times (k+1)},$$

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1k} \\ 1 & x_{21} & \cdots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{bmatrix}_{n \times (k+1)}, \quad \mathbf{1} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}_{(k+1) \times 1}.$$

GWR 模型 – 係數解

一般迴歸模型係數解 (最小平方法):

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

GWR 模型係數解 (局部加權最小平方法):

$$\hat{\beta}(u_i, v_i) = (\mathbf{X}^T \mathbf{W}(u_i, v_i) \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}(u_i, v_i) \mathbf{y},$$

where

$$\hat{\beta}(u_i, v_i) = \begin{bmatrix} \hat{\beta}_0(u_i, v_i) \\ \hat{\beta}_1(u_i, v_i) \\ \vdots \\ \hat{\beta}_k(u_i, v_i) \end{bmatrix}_{(k+1) \times 1}, \quad \text{the vector of estimated local regression coefficients at location } (u_i, v_i),$$

$$\mathbf{W}(u_i, v_i) = \begin{bmatrix} w_{i1} & 0 & \cdots & 0 \\ 0 & w_{i2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & w_{in} \end{bmatrix}_{n \times n}, \quad w_{ij} : \text{ the weight assigned to the } j\text{-th observation at location } i.$$

GWR 模型 – 權重函數選擇

全域迴歸: 不管資料點 j 離迴歸點 i 多遠, 權重都是 1

$$w_{ij} = 1 \quad \forall i, j$$

最簡單局部方法: 距離內算, 距離外不算

$$w_{ij} = \begin{cases} 1, & d_{ij} < d \\ 0, & o.w. \end{cases}$$

問題: 不連續且視窗內權重都是1, 本質上只是範圍較小的全域迴歸

GWR 模型 – 權重函數選擇

較好的方法: 讓權重隨距離平滑下降(高斯權重)

$$w_{ij} = \exp\left[-\frac{d_{ij}^2}{2b^2}\right]$$

問題: 即使很遠的資料點, 也會被乘上權重

bi-square 權重: 平滑下降, 但超過範圍直接歸 0

$$w_{ij} = \begin{cases} [1 - (\frac{d_{ij}}{b})^2]^2, & d_{ij} < b \\ 0, & o.w. \end{cases}$$

1. 不像應切的移動視窗, 內部權重都是 1
2. 明確排除太遠的資料點
3. GWR 常用權重函數

GWR 觀念: 帶寬 Bandwidth

定義: 帶寬 bandwidth

GWR 權重函數中的尺度參數，控制距離對空間權重的影響範圍。

帶寬越小，局部迴歸主要受鄰近觀測點影響，模型較能反映局部差異；

帶寬越大，較多觀測點參與估計，係數曲面較平滑，模型結果越接近全域迴歸。

- **固定帶寬 (fixed bandwidth):**

每個迴歸點採用相同範圍 b (空間資料密度不均時易導致估計偏誤)

- **可變帶寬 (adaptive bandwidth)**

資料點多的地方採用小範圍，資料點少的地方採用大範圍，保證每個迴歸點模型都使用合理資料量訓練

GWR 模型 – 可變帶寬形式

可變帶寬 1：用距離排序決定權重

$w_{ij} = \exp(\frac{-R_{ij}}{b})$, where R_{ij} : the rank of data point j at regression point i .

可變帶寬 2：讓每個點權重總和相同

$$\sum_j w_{ij} = C \forall i$$

GWR 模型 – 可變帶寬形式

可變帶寬 3 : 固定使用最近的 N 個鄰居 (最常見)

$$w_{ij} = \begin{cases} 1, & j \text{ is one of the } N \text{ points closest to the regression point } i. \\ 0, & o.w. \end{cases}$$

combine with bi-square:

$$w_{ij} = \begin{cases} [1 - (\frac{d_{ij}}{b})^2]^2, & j \text{ is one of the } N \text{ points closest to the regression point } i. \\ 0, & o.w. \end{cases}$$

GWR 模型 – 帶寬選擇

交叉驗證 CV: 預測 i 點時，不拿 i 點訓練

$$CV = \sum_{i=1}^n [y_i - \hat{y}_{\neq i}(b)]^2$$

廣義交叉驗證 GCV: 預測 i 點時，不拿掉 i 點，而是用複雜度懲罰模型

$$GCV = n \sum_{i=1}^n [y_i - \hat{y}_i(b)]^2 / (n - v_1)^2, \text{ where } v_1 = \text{tr}(\text{hat matrix } S)$$

AICc: 同時考慮模型配適度與複雜度，也可用在 Poisson GWR、Logistic GWR

$$AIC_c = 2n \log(\hat{\sigma}) + n \log(2\pi) + n \left[\frac{n + \text{tr}(S)}{n - 2 - \text{tr}(S)} \right]$$

BIC: 比 AICc 對模型複雜度施加更多懲罰，更傾向選擇簡單 (大帶寬) 模型

$$BIC = -2 \log(L) + k \log(n), \text{ where } L: \text{ model likelihood}$$

為何發展出 GCV ?

1. 比完整 CV 更容易計算 (不須排除迴歸點 i)
2. 透過複雜度懲罰避免 wrap-around effect

CV vs GCV

- CV: 較直接且概念清楚，但計算較慢
- GCV: 用有效參數限制來近似CV結果，計算較快，適合大量資料或需要反覆搜尋帶寬的情況

“An approximation to the cross-validation statistic that is easier to compute is known as the generalized cross-validation criterion (GCV).”
p.61

“This term prevents the calibration wrapping itself around the data points because v_1 would then tend to n and the denominator of equation would tend to 0. p.61

GWmodel

```
1 bw_cv <- bw.gwr(  
2   formula = formula_gwr,  
3   data = georgia_spdf,  
4   approach = "CV",  
5   kernel = "bisquare",  
6   adaptive = TRUE  
7 )  
8 bw_cv
```

手刻

```
1 calc_gwr_cv <- function(X, y, obs, bw){  
2   D <- calc_distance_matrix(obs, obs)  
3   n <- nrow(X)  
4   y_hat <- numeric(n)  
5   for(i in 1:n){  
6     w_i <- bisquare_adaptive_weight(D[i, ], bw)  
7  
8     # leave one out  
9     w_i[i] <- 0  
10  
11    # fit  
12    beta_i <- local_lwr(X, y, w_i)  
13    y_hat[i] <- X[i, ,drop=FALSE] %*% beta_i  
14  }  
15  cv <- sum((as.vector(y) - y_hat)^2)  
16  
17  return(cv)  
18 }
```

```
1 select_bw_cv <- function(X, y, obs, bw_candidates){  
2   cv_table <- data.frame(  
3     bw = bw_candidates,  
4     cv = NA  
5   )  
6   for (k in seq_along(bw_candidates)){  
7     bw_k <- bw_candidates[k]  
8     cv_k <- calc_gwr_cv(X=X, y=y, obs=obs, bw=bw_k)  
9     cv_table$cv[k] <- cv_k  
10  }  
11  
12  min_cv <- cv_table[which.min(cv_table$cv), ]  
13  
14  return(list(  
15    all_results = cv_table,  
16    best = min_cv  
17  ))  
18 }
```

GCV 實作

```
1 calc_gwr_gcv <- function(X, y, obs, bw){
2   D <- calc_distance_matrix(obs, obs)
3
4   n <- nrow(X)
5   y_hat <- numeric(n)
6   tr_S <- 0
7   for (i in 1:n){
8     # y_hat
9     w_i <- bisquare_adaptive_weight(D[i, ], bw)
10    beta_i <- local_lwr(X, y, w_i)
11    y_hat[i] <- X[i, ,drop=FALSE] %*% beta_i
12
13    # trace(S)
14    W_i <- diag(as.vector(w_i))
15    s_i <- X[i, ,drop=FALSE] %*% solve(t(X) %*% W_i %*% X) %*% t(
      X) %*% W_i # row i of S
16    tr_S <- tr_S + s_i[1, i]
17  }
18  gcv <- n * sum((as.vector(y) - y_hat)^2) / (n - tr_S)^2
19
20  return(gcv)
21 }
```

```
1 select_bw_gcv <- function(X, y, obs, bw_candidates){
2   gcv_table <- data.frame(
3     bw = bw_candidates,
4     gcv = NA
5   )
6   for(k in seq_along(bw_candidates)){
7     bw_k <- bw_candidates[k]
8     gcv_k <- calc_gwr_gcv(X=X, y=y, obs=obs, bw=bw_k)
9     gcv_table$gcv[k] <- gcv_k
10  }
11
12  min_gcv <- gcv_table[which.min(gcv_table$gcv), ]
13
14  return(list(
15    all_results = gcv_table,
16    best = min_gcv
17  ))
18 }
```

CV、GCV結果比較

直接使用理論計算方式，CV 計算效率優於 GCV

GCV在理論上為較容易計算CV的近似方法，然而實作上在計算有效參數數量時包含：


- 建立對角權重矩陣 $\mathbf{W}$
- 解反矩陣 (最耗效能)
- 帽子矩陣軌跡 $\text{tr}(\mathbf{S})$ 運算

改進方向


1. 用 `crossprod(X, X*w_i)`，避免建立 $\mathbf{W}$
2. 或許可用 Cholesky或 QR分解，避免解反矩陣
3. 計算 $\text{tr}(\mathbf{S})$ 時避免建構大量向量

	CV	GCV
最小值	2147.08	12.01
選擇帶寬	140	136
20次效能測試		
執行時間中位數	5.55	9.95
記憶體配置	4.99 GB	9.45 GB

CV Criterion



GCV Criterion



AIC、AICc 推導

$$\text{AIC} = -2 \left(\max_{\boldsymbol{\mu}, \sigma^2} \log L \right) + 2k,$$

where L : Likelihood function, k : number of estimated parameters

1. Maximum likelihood estimation

Let

$$\mathbf{y} \sim N_n(\boldsymbol{\mu}, \sigma^2 I_n).$$

The likelihood function is

$$L(\boldsymbol{\mu}, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\|\mathbf{y} - \boldsymbol{\mu}\|^2}{2\sigma^2}\right).$$

Therefore, the log-likelihood function is

$$\log L(\boldsymbol{\mu}, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{y} - \boldsymbol{\mu}\|^2.$$

Differentiating with respect to σ^2 , we obtain

$$\frac{\partial \log L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \|\mathbf{y} - \boldsymbol{\mu}\|^2 = 0.$$

Hence,

$$\hat{\sigma}^2 = \frac{\|\mathbf{y} - \hat{\boldsymbol{\mu}}\|^2}{n} = \frac{\text{RSS}}{n}.$$

Substituting the maximum likelihood estimator into the log-likelihood function gives

$$\begin{aligned} \max_{\boldsymbol{\mu}, \sigma^2} \log L &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}^2) - \frac{1}{2} \frac{n}{\text{RSS}} \text{RSS} \\ &= -\frac{n}{2} \log(2\pi) - n \log \hat{\sigma} - \frac{n}{2}. \end{aligned}$$

2. Number of parameters

The number of estimated parameters is

$$k = d + 1,$$

where d is the number of effective parameters and the additional parameter corresponds to σ^2 .

For a linear smoother with smoothing matrix S ,

$$d = \text{tr}(S).$$

Combining the results above, we obtain

$$\text{AIC} = 2n \log \hat{\sigma} + n \log(2\pi) + n + 2(\text{tr}(S) + 1).$$

The corrected Akaike Information Criterion is

$$\text{AICc} = \text{AIC} + \frac{2k(k+1)}{n-k-1}.$$

Thus,

$$\begin{aligned} \text{AICc} &= 2n \log \hat{\sigma} + n \log(2\pi) + n + 2(\text{tr}(S) + 1) \\ &\quad + \frac{2(\text{tr}(S) + 1)(\text{tr}(S) + 2)}{n - \text{tr}(S) - 2}. \end{aligned}$$

After simplification,

$$\boxed{\text{AICc} = 2n \log \hat{\sigma} + n \log(2\pi) + n \frac{n + \text{tr}(S)}{n - 2 - \text{tr}(S)}}.$$

GWR 檢驗參數非平穩 : Monte Carlo Permutation Test

- Test method: Monte Carlo permutation test
- H_0 : Spatial stationarity ($\beta_{ij} = \beta_j, \forall i$) vs. H_1 : Spatial nonstationarity (β_{ij} are not all equal)
- Test statistic: the standard deviation s_k of all local coefficients for a variable, where the k th coefficient measures spatial variation.
 - Small s_k : little variation across locations.
 - Large s_k : substantial variation across locations.
- Limitation: GWR must be rerun for every permutation, which is computationally expensive. Possible solutions are reducing the number of simulations or using representative subsamples.

GWR 檢驗參數非平穩：Monte Carlo Permutation Test

檢定範例

1. 令 y : 房價、 x : 所得水準、 (u,v) : 房屋位置、 $n=100$ 個房屋觀測點
2. 跑 GWR 得到每個地點所得係數 $\hat{\beta}_{income}(u_i, v_i)$ ，得市中心所得係數約 0.8，郊區約 0.2
3. 計算 100 個所得係數標準差，得 $s_{income}^{obs} = 0.25$
4. 隨機打亂房子位置，讓資料失去原本空間結構
5. 重跑 GWR，再次計算所得係數標準差
6. 重複步驟 4 與步驟 5，得大部分標準差 s_{income}^{rand} 落在 0.05-0.15，只有 2 次 > 0.25
7. 計算 P-value:

$$p = \frac{\text{隨機結果中比原始係數標準差更大的次數}}{\text{隨機打亂次數}} = \frac{2}{100} = 0.02$$

8. 結論: 在 5% 顯著水準下，所得對房價的影響具空間非平穩性

GWR 檢驗參數非平穩: F-test by Leung et al. (2000)

$$\hat{\mathbf{y}} = \mathbf{L}\mathbf{y}, \quad \hat{\boldsymbol{\varepsilon}} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{L})\mathbf{y},$$

where

$$\mathbf{L} = \begin{bmatrix} \mathbf{x}_1^\top (\mathbf{X}^\top \mathbf{W}(1) \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}(1) \\ \mathbf{x}_2^\top (\mathbf{X}^\top \mathbf{W}(2) \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}(2) \\ \vdots \\ \mathbf{x}_n^\top (\mathbf{X}^\top \mathbf{W}(n) \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}(n) \end{bmatrix}.$$

$$RSS_g = \hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}} = \mathbf{y}^\top (\mathbf{I} - \mathbf{L})^\top (\mathbf{I} - \mathbf{L}) \mathbf{y}.$$

$$\delta_i = \text{tr} \left\{ [(\mathbf{I} - \mathbf{L})^\top (\mathbf{I} - \mathbf{L})]^i \right\}, \quad i = 1, 2,$$

$$\hat{\sigma}^2 = \frac{RSS_g}{\delta_1}.$$

$$V_k^2 = \frac{1}{n} \sum_{i=1}^n \left(\hat{\beta}_{ik} - \frac{1}{n} \sum_{j=1}^n \hat{\beta}_{jk} \right)^2.$$

Equivalently,

$$V_k^2 = \frac{1}{n} \hat{\boldsymbol{\beta}}_k^\top \left(\mathbf{I} - \frac{1}{n} \mathbf{J} \right) \hat{\boldsymbol{\beta}}_k,$$

where $\mathbf{J}$ is an $n \times n$ matrix whose elements are all equal to one.

$$\gamma_i = \text{tr} \left\{ \left[\frac{1}{n} \mathbf{B}_k^\top \left(\mathbf{I} - \frac{1}{n} \mathbf{J} \right) \mathbf{B}_k \right]^i \right\}, \quad i = 1, 2.$$

$$\hat{\boldsymbol{\beta}}_k = \begin{bmatrix} \hat{\beta}_{1k} & \hat{\beta}_{2k} & \cdots & \hat{\beta}_{nk} \end{bmatrix}^\top = \mathbf{B}_k \mathbf{y},$$

where

$$\mathbf{B}_k = \begin{bmatrix} \mathbf{e}_k^\top (\mathbf{X}^\top \mathbf{W}(1) \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}(1) \\ \mathbf{e}_k^\top (\mathbf{X}^\top \mathbf{W}(2) \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}(2) \\ \vdots \\ \mathbf{e}_k^\top (\mathbf{X}^\top \mathbf{W}(n) \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}(n) \end{bmatrix}.$$

Leung F3 Test

$$H_0 : \beta_{1k} = \beta_{2k} = \cdots = \beta_{nk},$$

$$H_1 : \text{ not all } \beta_{ik}, \quad i = 1, \dots, n, \text{ are equal,}$$

$$F_3(k) = \frac{V_k^2 / \gamma_1}{\hat{\sigma}^2} \stackrel{H_0}{\sim} F \left(\frac{\gamma_1^2}{\gamma_2}, \frac{d_1^2}{d_2} \right)$$

$$\text{Reject } H_0 \text{ if } F_3(k) \geq F_\alpha \left(\frac{\gamma_1^2}{\gamma_2}, \frac{d_1^2}{d_2} \right).$$

GWR 檢驗參數非平穩: F-test by Leung et al. (2000)

Leung F3 test 比較表

比較項目	Leung <i>et al.</i> (2000)	Fotheringham <i>et al.</i> (2002)	GWmodel
係數變異統計量	$V_k = (1/n) \hat{\beta}_k^T C \hat{\beta}_k$	相同	相同
V_k 尺度量	$\gamma_1 = tr(G_k)$	相同	相同
F3 統計量	$F_{3,k} = \frac{V_k / \gamma_1}{RSS_g / \delta_1}$	相同	相同
V_k 二次型二階量	$\gamma_2 = tr(G_k^2)$	不使用	$\gamma_2 = \sum_{i=1}^n (G_{k,ii})^2$
分子自由度	$\nu_1 = \frac{\gamma_1^2}{\gamma_2}$	$\nu_1 = \gamma_1$	$\nu_1 = \frac{\gamma_1^2}{\gamma_2}$
殘差二次型一階量	$\delta_1 = tr(Q)$	相同	相同
殘差二次型二階量	$\delta_2 = tr(Q^2)$	不使用	$\delta_2 = 0$
分母自由度	$\nu_2 = \frac{\delta_1^2}{\delta_2}$	$\nu_2 = \delta_1$	$\nu_2 = \infty$
近似分配	$F_{3,k} \sim F\left(\frac{\gamma_1^2}{\gamma_2}, \frac{\delta_1^2}{\delta_2}\right)$	$F_{3,k} \sim F(\gamma_1, \delta_1)$	$F_{3,k} \sim F\left(\frac{\gamma_1^2}{\gamma_2}, \infty\right)$
理論定位	二階近似，較完整	一階 trace 簡化近似	package 特有實作

$$C = I - \frac{1}{n}J, \quad G_k = \frac{1}{n}B_k^T C B_k, \quad Q = (I - S)^T(I - S).$$

GWR 信賴區間

GWR信賴區間推導方法: 加權最小平方法轉換為矩陣 C

$$\hat{\beta}(u_i, v_i) = (\mathbf{X}^T \mathbf{W}(u_i, v_i) \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}(u_i, v_i) \mathbf{y} = \mathbf{C}(u_i, v_i) \mathbf{y}$$

where

$\mathbf{X}$: matrix of independent-variable data,

$\mathbf{y}$: vector of dependent-variable data,

$\mathbf{W}(u_i, v_i)$: weight matrix,

$\hat{\beta}(u_i, v_i)$: vector of locally estimated coefficients.

Under the model assumptions,

$$\text{Var}(\mathbf{y}) = \sigma^2 \mathbf{I} \quad \text{and} \quad \hat{\beta}(u_i, v_i) = \mathbf{C}_i \mathbf{y}.$$

Therefore,

$$\text{Var}(\hat{\beta}(u_i, v_i)) = \mathbf{C}_i \mathbf{C}_i^T \sigma^2.$$

For the coefficient $\beta_j(u_i, v_i)$, the confidence interval is derived from

$$\text{Var}(\hat{\beta}(u_i, v_i)) = \mathbf{C}_i \mathbf{C}_i^T (u_i, v_i) \sigma^2,$$

which gives

$$\text{SE}(\hat{\beta}_j(u_i, v_i)) = \sqrt{(\mathbf{C}_i \mathbf{C}_i^T)_{jj} \sigma^2}.$$

Hence, the confidence interval for β_j is

$$\hat{\beta}_j \pm z_{\alpha/2} \text{SE}(\hat{\beta}_j),$$

or, when σ^2 is estimated and a t -distribution is used,

$$\hat{\beta}_j \pm t_{\alpha/2, \text{df}} \text{SE}(\hat{\beta}_j).$$

模擬實驗發現此信賴區間涵蓋率不穩定

參考 Fotheringham et al. (2002). Geographically Weighted Regression. pp.97-102 估計流程:

1. 使用資料: 喬治亞州縣級資料
2. 使用 N 近鄰 bandwidth 搭配 bi-square 權重
3. 測試多個 bandwidth，選擇 AICc 表現最好的模型
4. 於地圖範圍設置 40*40 網格作為迴歸點
5. 於迴歸點訓練模型
6. 將各解釋變數之局部迴歸係數視覺化

GWR 實作: 資料介紹

使用 GWmodel 套件內建之 Georgia census data set

- 美國喬治亞州縣級人口普查資料
- 每筆觀測值代表喬治亞州的一個縣
- 159 筆觀測值、13 個變數

模型設定:


$$\begin{aligned} PctBach_i &= \beta_0(i) \\ &+ \beta_1(i)PctRural_i \\ &+ \beta_2(i)PctEld_i \\ &+ \beta_3(i)PctFB_i \\ &+ \beta_4(i)PctPov_i \\ &+ \beta_5(i)PctBlack_i \\ &+ \epsilon_i \end{aligned}$$

where i: ith point in the space.

變數名稱	角色	變數說明
AreaKey	識別變數	各 county 的識別編號
Latitude	座標變數	County centroid 的緯度
Longitud	座標變數	County centroid 的經度
TotPop90	背景變數	1990 年 county 總人口數
PctBach	應變數	County 中具學士學位的人口比例
PctRural	解釋變數	County 中被定義為 rural population 的人口比例
PctEld	解釋變數	County 中 65 歲以上人口比例
PctFB	解釋變數	County 中非美國出生人口比例
PctPov	解釋變數	County 中低於貧窮線人口比例
PctBlack	解釋變數	County 黑人人口比例
ID	識別變數	數值型 ID
X	空間座標	County centroid 的 X 座標
Y	空間座標	County centroid 的 Y 座標

Source: package 'GWmodel' documentation pp.16-17

GWR 實作: 流程概述



GWR 實作: 使用 R Package “GWmodel”

bw.gwr() 參數內容

參數	意義	報告設定
formula	迴歸模型公式，指定 y 和 x 變數	PctBach ~ PctRural + PctEld + PctFB + PctPov + PctBlack
data	空間資料，須為Spatial*DataFrame 或 sf 物件	將套件原廠資料轉換為 SPDF
approach	bandwidth 選擇方法，可用 CV 或 AICc	approach = "AICc"
kernel	空間權重函數，決定距離如何轉成權重	kernel = "bisquare"
adaptive	是否使用 adaptive bandwidth	adaptive = TRUE
p	Minkowski distance 次方數，p = 2 是歐式距離	預設 p = 2
theta	是否旋轉座標系統，用於調整距離方向	預設 theta = 0
longlat	是否使用經緯度大圓距離	預設 FALSE
dMat	事先算好的距離矩陣	省略 (p=2 已自動計算距離)
parallel.method	是否使用平行運算	預設 FALSE
parallel.arg	平行運算的細部設定	預設 Null

輸出: 參數設定下最佳 bandwidth

Source: package ‘GWmodel’ documentation p.10

GWR 實作: 使用 R Package “GWmodel”

gwr.basic() 參數內容

參數	意義	報告設定
formula	迴歸模型公式	PctBach ~ PctRural + PctEld + PctFB + PctPov + PctBlack
data	空間資料，須為 Spatial*DataFrame 或 sf 物件	educ.spdf
regression.points	指定在哪些位置估計 local coefficients	40*40網格點
bw	bandwidth	bw.gwr()選定之最佳bandwidth
kernel	空間權重函數	"bisquare"
adaptive	是否使用 adaptive bandwidth	TRUE
p	Minkowski distance 的次方，p = 2 是歐式距離	預設 2
theta	是否旋轉座標系統	預設 0
longlat	是否使用經緯度大圓距離	預設 FALSE
dMat	事先算好的距離矩陣	省略
F123.test	是否進行 Leung 三個 F-tests	預設 FALSE
cv	是否計算 cross-validation 結果並放入輸出	預設 FALSE
W.vect	額外給定觀測值權重	預設 NULL
x	print() method 用，gwr.basic() 回傳的物件	不需自己設定
parallel.method	是否用平行運算	預設 FALSE
parallel.arg	平行運算的細部設定	預設 NULL

GWR 實作: 使用 R Package “GWmodel”

`gwr.basic()` 回傳內容

回傳項目	意義	報告設定
GW.arguments	儲存 GWR 模型參數設定	V
GW.diagnostic	模型診斷結果，如 RSS、AICc、 R^2	V
lm	對應的 global linear regression 結果	V
SDF	最重要的輸出，包含每個地點的 local coefficients、yhat、residual、standard errors、t-values 等	V
timings	模型開始與結束時間	X
this.call	當初執行的 function call	X
Ftest.res	若 <code>F123.test = TRUE</code> ，這裡會存 Leung's F-tests 結果	X

Source: package ‘GWmodel’ documentation p.40

GWR 實作: 手刻程式碼

基本估計函數設計:

函數	參數	輸出
grid()	x, nrow, y, ncol	nrow * ncol 網格點
cal_distance_matrix()	grid, obs	所有迴歸點至所有觀測點之距離矩陣
bisquare_adaptive_weight()	d, bw	各觀測點之於單一迴歸點之權重向量
local_lwr()	X, y, w	單一迴歸點之係數解
gwr_grid()	X, y, obs, grid, bw	所有迴歸點之係數解



迴圈次數 = 迴歸點個數

初始全域變數

選擇最佳 bandwidth (最小AICc):

函數	參數	輸出
calc_gwr_aicc	X, y, obs, bw	bandwidth=bw 下之 AICc
select_bw_aicc	X, y, obs, bw_canditates	1. 所有候選 bandwidths 之 AICc 2. 最佳bandwidth (最小AICc)



loop


套件與手刻結果比較

項目	GWmodel	手刻
Bandwidth 選擇	136	136
最小 AICc	850.8465	850.8465
係數估計差距最大值	2.334e-12	

GWR 實作: 視覺化(40*40網格迴歸點版本)

- 係數估計位置: 40 * 40 迴歸點
- 顏色意義: 各迴歸點估計值
- 州界外處理: NA 遮罩
- 結果: 各個變數均有一定程度之空間差異

(e.g.) PctBlack 在西南部係數較高，代表其在該區域正向關係較強。



顏色設定 100 種，將預測值值域切成 100 個區間


GWR 實作: 視覺化(40*40網格迴歸點版本)

R 內建參數 `image()`: 須建立 XY 矩形網格座標

主要參數	說明
x	x 座標範圍
y	y 座標範圍
z	座標值
col	顏色種類
breaks	區間
xlab	x軸名稱
ylab	y軸名稱
main	大標

Source: R document

<https://www.rdocumentation.org/packages/graphics/versions/3.6.2/topics/image>



顏色設定 6 種，將預測值值域切成 6 個區間

GWR 檢驗參數非平穩：Monte Carlo Permutation Test

```
1 set.seed(123)
2 mc <- gwr.montecarlo(formula=formula_gwr,
3                       data=georgia_spdf,
4                       nsims=1000,
5                       kernel="bisquare",
6                       adaptive=TRUE,
7                       bw=bw_aicc)
```

GWmodel

```
1 mc_per <- function(X, y, obs, bw, sims, seed=123){
2   set.seed(seed)
3   sd_ori <- gwr_grid(X=X, y=y, obs=obs, grid=obs, bw=bw)$coef_sd
4   k <- length(sd_ori)
5
6   # whether simulation std. is larger than original std.
7   larger_than_ori <- matrix(NA, nrow=sims, ncol=k)
8   colnames(larger_than_ori) <- names(sd_ori)
9
10  # std. of random location beta
11  sd_rand_mat <- matrix(NA, nrow=sims, ncol=k)
12  colnames(sd_rand_mat) <- names(sd_ori)
13
14  for (i in 1:sims){
15    # permutation
16    obs_rand <- obs[sample(1:nrow(obs)), ]
17
18    # std. of randomized beta
19    sd_rand <- gwr_grid(X=X, y=y, obs=obs_rand, grid=obs_rand, bw
20                      =bw)$coef_sd
21    sd_rand_mat[i, ] <- sd_rand
22  }
23
24  # calculate p-value
25  pv <- colMeans(sd_rand_mat >= matrix(sd_ori, nrow=sims, ncol=k,
26                                     byrow=TRUE))
27
28  return(pv)
29 }
```

手刻

GWR 檢驗參數非平穩：Monte Carlo Permutation Test

係數	p-value(GWmodel)	p-value(手刻)
Intercept	0.375	0.379
PctRural	0.331	0.324
PctEld	0.658	0.640
PctFB	0.002	0.004
PctPov	0.414	0.433
PctBlack	0.034	0.030

GWR 檢驗參數非平穩: F-test by Leung et al. (2000)

GWmodel

```
1 ftest <- gwr.basic(formula=formula_gwr,
2                     data=georgia_spdf,
3                     bw=bw_aicc,
4                     kernel="bisquare",
5                     adaptive=TRUE,
6                     F123.test=TRUE)
```

變數	F3 statistic	Numerator DF	Denominator DF	Pr(>F)
Intercept	1.37932	48.9944	Inf	0.04029
PctRural	1.39656	61.83326	Inf	0.02144
PctEld	0.43555	51.91984	Inf	0.99987
PctFB	14.56198	29.99224	Inf	< 2.2E-16
PctPov	3.41707	29.23114	Inf	1.19E-09
PctBlack	5.0173	64.17467	Inf	< 2.2E-16

Leung et al. (2000)

```
1 calc_leung_f3 <- function(X, y, beta_mat, B_list, L){
2   ...
3   return(list(
4     table = F3_result,
5     RSS_g = RSS_g,
6     delta_1 = delta_1,
7     delta_2 = delta_2,
8     sigma_hat_sq = sigma_hat_sq,
9     denominator_df = denominator_df
10  ))
11 }
12 leung_f3 <- gwr_grid(X=X, y=y, obs=obs_xy, grid=obs_xy, bw=
  bw_aicc, F3=TRUE)$F3$table
```

變數	F3 statistic	Numerator DF	Denominator DF	Pr(>F)
Intercept	1.379318	2.660224	145.8743	0.253384
PctRural	1.396558	2.588568	145.8743	0.248858
PctEld	0.435545	2.77371	145.8743	0.712558
PctFB	14.56199	2.433527	145.8743	2.55E-07
PctPov	3.417074	2.40523	145.8743	2.75E-02
PctBlack	5.0173	2.355922	145.8743	0.005122

參考 Wheeler & Calder (2007). J Geogr Syst, 9(2), 145-166. 實作 GWR 模擬實驗

- **原論文內容**

設計模擬實驗，比較地理加權迴歸(GWR)與空間隨位置變動係數過程(SVCP)在不同共線性程度下，準確度 (RMSE) 與區間估計 (95%信賴區間與可信區間) 的可靠性

- **實作內容**

復刻 3.1 simulation 1 中 GWR 模擬流程與結果

1 模擬目的

1. 在解釋變數沒有明顯共線性的條件下，GWR 推論是否可靠
2. GWR 能否準確估計隨空間變化的迴歸係數
3. GWR 建立的 95% 信賴區間是否能夠涵蓋真實函數
4. 不同誤差情形，結果是否一致

2 空間樣本配置


1. $10 * 10$ 網格，樣本數 $n=100$
2. 座標 $(1,1), (2,1), \dots, (10, 10)$

3 真實迴歸係數設定

1. $\beta_1^*(s)$ 的值為該位置 x 座標
2. $\beta_2^*(s)$ 的值為該位置 y 座標

呈現情境:

- 平滑的空間變化
- 清楚的線性空間趨勢
- 明顯空間非平穩
- 固定不變的係數表面



4 解釋變數產生

1. 產生十維資料: 由 $Z_i \sim N_{10}(\mathbf{0}, \mathbf{I}_{10})$ 生成 100 筆資料
2. PCA ($100 \times 10 \rightarrow 100 \times 2$): 取前 2 個主成分作為 x_1, x_2 , 模擬無共線性環境
3. 每次模擬皆重新產生資料

5 反應變數產生

無截距模型:

$$y(s_i) = \beta_1^*(s_i)x_1(s_i) + \beta_2^*(s_i)x_2(x) + \epsilon(s_i)$$

6 誤差項設定

在各地間獨立生成:

$$\epsilon(s_i) \stackrel{ind.}{\sim} N(0, \tau^{2*})$$

1. 情境 A : 極小誤差 $\tau^{2*} = 0.001$, 檢查乾淨資料下 GWR 能否準確還原真實係數
2. 情境 B : 較大誤差 $\tau^{2*} = 1$, 確認結果是否會因誤差程度改變

7 模擬次數

$R=200$, $\tau^{2*} = 0.001$ 與 $\tau^{2*} = 1$ 各 200 次

在每次模擬中:

- 空間網格座標固定
- 真實係數固定
- 解釋變數重新生成
- 誤差重新生成
- 反應變數重新計算
- GWR 重新用 LOOCV 選擇帶寬
- GWR 重新估計所有迴歸係數

8 GWR 核函數設定

指數核函數:

$$w_j(s) = \exp\left(-\frac{d_{sj}}{b}\right)$$

其中 d_{sj} : 迴歸點 s 與觀測點 j 的距離 ; b : 帶寬

9 帶寬選擇：LOOCV

10 配適 GWR 模型

11 計算GWR係數標準
誤與信賴區間

12 信賴區間涵蓋率計算

先計算每個地點在 200 次模擬的涵蓋率，再對 100 個地點取平均

每次模擬 r ，對每個位置 s_i ，每個係數 $\beta_k^*(s_i)$ ，檢查是否落在該次模擬得到的 95% 信賴區間內

$$I_{ikr} = \begin{cases} 1, & \beta_k^*(s_i) \in CI_{ikr}^{95\%} \\ 0, & \text{otherwise} \end{cases}$$

對特定位置涵蓋率：

$$CP_{ik} = \frac{1}{200} \sum_{r=1}^{200} I_{ikr}$$

將同一位置在 100 個位置中的 CP 取平均，得到論文結果中的 $MeanCP(\beta_k)$

13 RMSE計算

對每次模擬，計算全部空間位置與係數的 RMSE (100個位置、200個係數)：

$$RMSE_r = \sqrt{\frac{1}{200} \sum_{i=1}^{100} \sum_{k=1}^2 [\hat{\beta}_{k,r}(s_i) - \beta_k^*(s_i)]^2}$$

再將 200 次模擬的 RMSE 取平均：

$$\overline{RMSE} = \frac{1}{200} RMSE_r$$

將此 RMSE 平均作為 GWR 係數準確度的衡量指標

GWR 網格模擬 – 程式碼架構

①

主要函數與流程

1. global_parameter_config()

- 設定模擬參數
- 10 * 10 空間網格 (n = 100)
- raw_dim=10、PCA 後保留 2 個解釋變數
- sims=200、error_var={0.001, 1}
- 95% CI、seed = 123
- GWR: 無截距、exponential kernel、fixed bandwidth、LOOCV

2. grid_setup(parameter)

- 建立 (x,y) 座標網格
- 取出所有 (x,y) 座標
- 計算距離矩陣

3. true_coef_setup(grid)

- 設定真實係數
- beta1_true=grid\$x_coord
- beta2_true=grid\$y_coord

4. run_sim(parameter, grid, true_coef)

- 核心模擬函數
- 外層: 兩種誤差情境 (error_var={0.001, 1})
- 內層: 每種情境模擬 200 次

5. 輸出結果

- all_results
- summary_table

②

run_sim()內圈 200 次模擬流程

- 1 產生 100 * 10 原始資料: $Z_i \sim N_{10}(0, I_{10})$
- 2 PCA: 取前 2 主成分作為 x_1, x_2
- 3 生成誤差 $\epsilon(s_i) \stackrel{ind.}{\sim} N(0, \tau^{2*})$
- 4 建立反應變數 $y(s_i) = \beta_1^*(s_i)x_1(s_i) + \beta_2^*(s_i)x_2(x) + \epsilon(s_i)$
- 5 使用 GWmodel 的 bw_gwr() 選最佳帶寬
- 6 使用 GWmodel 的 gwr.basic() 估計各點係數
- 7 計算係數標準誤並建立 95% CI
- 8 計算信賴區間涵蓋率與 RMSE

③

模擬重點與輸出指標

A. 模擬目的

- 解釋變數無明顯共線性情況下，GWR 推論是否可靠
- GWR 是否能準確還原空間變動係數
- 95% CI 是否能涵蓋真實係數
- 結果是否受誤差大小影響

B. 主要評估指標

- RMSE
- Mean CP (β_1)
- Mean CP (β_2)

①

論文模擬實驗結果

Table 1 Average root mean square error (RMSE) and percent coverage (CP) of the 95% confidence intervals of the regression coefficients with GWR and percent coverage of the 95% credible intervals with the SVCP model in simulation study 1 with true error variance = 0.001

Method	RMSE (β)	Mean CP (β_1)	Mean CP (β_2)
Bayesian	0.138	100%	100%
GWR	0.414	63%	63%

Table 2 Average root mean square error (RMSE) and percent coverage (CP) of the 95% confidence intervals of the regression coefficients with GWR and percent coverage of the 95% credible intervals with the SVCP model in simulation study 1 with true error variance = 1

Method	RMSE (β)	Mean CP (β_1)	Mean CP (β_2)
Bayesian	0.452	98%	98%
GWR	0.595	82%	82%

②

復刻模擬實驗結果

```
> summary_table
  error_var mean_rmse mean_cp_beta1 mean_cp_beta2
1    0.001 0.4142061      0.63190      0.6339
2    1.000 0.5801574      0.81255      0.8181
```